POLITECHNIKA POZNAŃSKA

WYDZIAŁ INFORMATYKI I TELEKOMUNIKACJI
Instytut Informatyki

Praca dyplomowa licencjacka

SPRZĘTOWY GENERATOR LICZB LOSOWYCH WYKORZYSTUJĄCY RZUTY KOSTKĄ

Julia Samp, 151775
Jakub Kędra, 151790
Wojciech Kot, 151879
Jakub Prusak, 151178

Promotor
dr inż. Jędrzej Potoniec

POZNAŃ 2025

Spis treści

Rozdział 1

Wstęp

Wstęp do pracy powinien zawierać następujące elementy:

- krótkie uzasadnienie podjęcia tematu;
- cel pracy (patrz niżej);
- zakres (przedmiotowy, podmiotowy, czasowy) wyjaśniający, w jakim rozmiarze praca będzie realizowana;
- ewentualne hipotezy, które autor zamierza sprawdzić lub udowodnić;
- krótką charakterystykę źródeł, zwłaszcza literaturowych;
- układ pracy (patrz niżej), czyli zwięzłą charakterystykę zawartości poszczególnych rozdziałów;
- ewentualne uwagi dotyczące realizacji tematu pracy np. trudności, które pojawiły się w trakcie realizacji poszczególnych zadań, uwagi dotyczące wykorzystywanego sprzętu, współpraca z firmami zewnętrznymi.

No więc co do tego i tamtego testy kurde ten. lol.
xD
tak.

Rozdział 2

Fragment teoretyczny

Współczesne systemy kryptograficzne oraz aplikacje wymagają generowania liczb losowych, które muszą charakteryzować się wysoką jakością i odpornością na przewidywalność. Najlepiej spełniają te wymagania generatory liczb losowych oparte na fizycznych zjawiskach, zwane TRNG (True Random Number Generator). TRNG są szczególnie istotne w kontekście aplikacji wymagających silnej ochrony danych, takich jak systemy kryptograficzne, podpisy cyfrowe oraz generowanie kluczy szyfrujących.

2.1 Zalety dostępnych rozwiązań

AAAAAAAAAAAAAAAAAAAAAAAAAAAAAA

2.2 Wady dostępnych rozwiązań TRNG

Generatory Liczb Losowych Oparte na Zjawiskach Fizycznych (TRNG) oferują niezrównaną jakość losowości, jednak ich wdrożenie i użytkowanie wiąże się z pewnymi wyzwaniami. Do najważniejszych problemów można zaliczyć wydajność, koszty implementacji, stabilność, złożoność integracji oraz aspekty bezpieczeństwa.

2.2.1 Wydajność, koszty i stabilność

Wydajność TRNG jest zazwyczaj niższa niż w przypadku generatorów pseudolosowych (PRNG). Proces generowania liczb losowych przy użyciu zjawisk fizycznych, takich jak szum termiczny czy fluktuacje kwantowe, może być czasochłonny, co sprawia, że TRNG mogą nie spełniać wymagań aplikacji o wysokiej częstotliwości operacji kryptograficznych.

Urządzenia TRNG, szczególnie te oparte na zaawansowanych technologiach, są kosztowne w produkcji i utrzymaniu. Wysokie koszty związane są z wykorzystaniem specjalistycznych komponentów, takich jak elementy fotoniki kwantowej czy czujniki szumów kwantowych. Jednocześnie jakość generowanych liczb losowych może być wrażliwa na czynniki zewnętrzne, takie jak zakłócenia elektromagnetyczne czy zmiany temperatury, co wymaga dodatkowych mechanizmów korekcji.

2.2.2 Integracja i skalowalność

Integracja TRNG z istniejącymi systemami może być skomplikowana, szczególnie w przypadku systemów wbudowanych. Konieczne bywa dostosowanie sprzętu lub oprogramowania, co zwiększa złożoność projektu i jego koszty. Ponadto TRNG nie zawsze są skalowalne, co może być problematyczne w aplikacjach wymagających elastyczności lub masowej produkcji.

2.2.3 Bezpieczeństwo i inne ograniczenia

Chociaż TRNG oferują wyższy poziom bezpieczeństwa niż PRNG, nie są one całkowicie odporne na ataki. Manipulacje fizyczne lub przechwytywanie sygnałów generowanych przez urządzenie mogą prowadzić do obniżenia jakości generowanych liczb losowych. W przypadku rozwiązań opartych na chmurze istnieje dodatkowe ryzyko związane z transmisją danych, co może wpływać na ich bezpieczeństwo.

2.3 Podsumowanie wad TRNG

TRNG oferują wysoki poziom losowości, ale wiążą się z wyzwaniami, takimi jak niska wydajność, wysokie koszty, wrażliwość na zakłócenia, skomplikowana integracja oraz zagadnienia bezpieczeństwa. Mimo to są niezastąpione w aplikacjach wymagających maksymalnego poziomu ochrony danych, a dalszy rozwój technologii może przyczynić się do przezwyciężenia obecnych ograniczeń.

Rozdział 3

Przegląd komercyjnych rozwiązań TRNG

Współczesne systemy kryptograficzne oraz aplikacje wymagają generowania liczb losowych, które muszą charakteryzować się wysoką jakością i odpornością na przewidywalność. Najlepiej spełniają do generatory liczb losowych oparte na fizycznych zjawiskach, zwane TRNG (True Random Number Generator). TRNG są szczególnie istotne w kontekście aplikacji wymagających silnej ochrony danych, takich jak systemy kryptograficzne, podpisy cyfrowe, oraz w generowaniu kluczy szyfrujących.

3.1 Rozwiązania sprzętowe

Wśród komercyjnych rozwiązań sprzętowych, wiodącymi producentami są firmy takie jak **ID Quantique**, **Microchip Technology** i **Semtech**, które oferują zaawansowane urządzenia bazujące na TRNG. Produkty te zapewniają wysoki poziom bezpieczeństwa i są stosowane w wymagających aplikacjach, takich jak bankowość elektroniczna czy systemy wojskowe.

- **ID Quantique** jest jednym z liderów w dziedzinie generatorów liczb losowych opartych na technologii fotoniki. Firma oferuje urządzenia, które wykorzystują detekcję fotonów w celu generowania liczb losowych. Dzięki temu rozwiązania ID Quantique charakteryzują się bardzo wysoką jakością losowości, a jednocześnie są odporne na ataki związane z analizą i przewidywaniem generowanych liczb.
- **Microchip Technology** w swojej ofercie posiada różne moduły TRNG, w tym układy scalone, które generują liczby losowe na podstawie fluktuacji szumów termicznych. Produkty te znajdują zastosowanie w szerokim zakresie aplikacji, od urządzeń mobilnych po systemy wbudowane.
- **Semtech** natomiast oferuje rozwiązania, które wykorzystują zjawiska losowe zachodzące w obwodach analogowych do generowania liczb losowych. Firma ta jest jednym z głównych dostawców układów TRNG, które znajdują szerokie zastosowanie w urządzeniach IoT oraz w systemach komunikacji bezprzewodowej.

3.2 Generatory TRNG w chmurze

W ostatnich latach pojawiły się także rozwiązania chmurowe, które umożliwiają generowanie liczb losowych w czasie rzeczywistym bez potrzeby posiadania własnego sprzętu. Przykładem takiego rozwiązania jest **Cloudflare** – firma specjalizująca się w dostarczaniu usług związanych z

bezpieczeństwem sieciowym. Na swoim blogu Cloudflare przedstawia zaawansowane metody generowania liczb losowych, które są wykorzystywane w ich systemach. Cloudflare korzysta z technologii opartych na zjawiskach fizycznych, takich jak detekcja fizycznych "bąbli"w lampach lawowych ("Entropy Wall"), nieprzewidywalnego fizycznie trójstopniowego wahadła, rozpadu radioaktywnego Uranu oraz procesów związane z tzw. "chaosem kwantowym". Tego typu rozwiązania pozwalają na szybkie i bezpieczne generowanie liczb losowych w skali globalnej, zapewniając jednocześnie wysoki poziom ochrony przed atakami.

Firma ta oferuje użytkownikom dostęp do generatora liczb losowych w chmurze, który jest wykorzystywany m.in. do tworzenia kluczy kryptograficznych oraz w innych zastosowaniach wymagających silnych zabezpieczeń. Dzięki wykorzystaniu globalnej infrastruktury Cloudflare, generowane liczby losowe są szeroko dostępne i charakteryzują się dużą niezawodnością oraz odpornością na ataki.

3.3 Wady dostępnych rozwiązań TRNG

Mimo że Generatory Liczb Losowych Oparte na Zjawiskach Fizycznych (TRNG) oferują wysoki poziom bezpieczeństwa i losowości, istnieje kilka istotnych wad i ograniczeń związanych z ich implementacją i użytkowaniem. Wśród głównych problemów, które mogą wpływać na wydajność oraz niezawodność TRNG, wyróżnia się następujące aspekty:

3.3.1 Wydajność i szybkość generowania liczb losowych

Wydajność TRNG jest często niższa niż w przypadku Generujących Liczby Losowe Oparte na Algorytmach (PRNG). Generowanie liczb losowych za pomocą zjawisk fizycznych, takich jak szum termiczny czy fluktuacje kwantowe, może być procesem czasochłonnym, szczególnie w systemach wymagających dużych ilości losowych liczb w krótkim czasie. W wyniku tego, TRNG mogą nie spełniać wymagań wydajnościowych w aplikacjach o dużym zapotrzebowaniu na losowość, takich jak systemy kryptograficzne o bardzo wysokiej częstotliwości operacji.

3.3.2 Koszty implementacji

Urządzenia TRNG, zwłaszcza te oparte na zaawansowanych technologiach, takich jak fotonika kwantowa czy detekcja szumów kwantowych, mogą wiązać się z wysokimi kosztami produkcji oraz utrzymania. Z tego powodu, TRNG są często droższe w porównaniu do bardziej ekonomicznych rozwiązań opartych na algorytmach deterministycznych (PRNG), które wystarczają do wielu zastosowań, gdzie wysoka jakość losowości nie jest kluczowym wymaganiem.

3.3.3 Stabilność i jakość generowanych liczb losowych

Choć TRNG są uznawane za bezpieczne, ich jakość może być wpływana przez różne czynniki zewnętrzne, takie jak temperatura, zakłócenia elektromagnetyczne czy inne zmiany środowiskowe. W wyniku tego, generowane liczby losowe mogą wykazywać pewne niskiej jakości właściwości, co wymaga zastosowania dodatkowych mechanizmów, takich jak procesy post-przetwarzania, aby zapewnić ich odpowiednią losowość. Nawet małe zakłócenia w systemie mogą prowadzić do wzorców, które mogą zostać wykorzystane w atakach kryptograficznych.

3.3.4 Skomplikowana kalibracja i konserwacja

Urządzenia TRNG, szczególnie te, które wykorzystują skomplikowane zjawiska fizyczne, wymagają starannej kalibracji i ciągłego monitorowania, aby zapewnić ich prawidłowe funkcjonowanie. W wielu przypadkach konieczne jest stosowanie systemów nadzoru, które monitorują jakość generowanych liczb losowych w czasie rzeczywistym. Ponadto, wymogi dotyczące utrzymania odpowiednich warunków pracy, takich jak stabilna temperatura czy brak zakłóceń elektromagnetycznych, mogą stanowić dodatkową przeszkodę w ich szerokim zastosowaniu.

3.3.5 Złożoność integracji z istniejącymi systemami

Integracja TRNG z już działającymi systemami, zwłaszcza w kontekście urządzeń wbudowanych lub systemów o dużych wymaganiach obliczeniowych, może wiązać się z wieloma trudnościami. Często konieczne jest dostosowanie sprzętu lub oprogramowania w celu zapewnienia kompatybilności i pełnej funkcjonalności. Dodatkowo, ze względu na fizyczną naturę tych urządzeń, integracja z innymi komponentami może prowadzić do wzrostu kosztów oraz złożoności całego systemu.

3.3.6 Ograniczona dostępność i skalowalność

Choć rynek TRNG rośnie, nadal jest on stosunkowo niszowy w porównaniu do bardziej powszechnych rozwiązań opartych na PRNG. Ograniczona dostępność wyspecjalizowanych urządzeń TRNG, szczególnie tych, które oferują wysoką jakość generowanych liczb losowych, sprawia, że ich wdrożenie jest trudniejsze, zwłaszcza w przypadkach wymagających masowej produkcji. Ponadto, nie wszystkie rozwiązania są skalowalne, co może być problemem w przypadku aplikacji wymagających elastyczności i łatwego dostosowywania wydajności do rosnących potrzeb.

3.3.7 Zagadnienia związane z bezpieczeństwem

Chociaż TRNG zapewniają wyższy poziom bezpieczeństwa niż PRNG, nie są one całkowicie odporne na ataki. Ataki fizyczne, takie jak manipulacje w obrębie urządzenia lub przechwytywanie sygnałów z jego elementów, mogą prowadzić do kompromitacji jakości liczb losowych. Ponadto, w przypadku rozwiązań opartych na technologii chmurowej, takich jak te oferowane przez Cloudflare, istnieje ryzyko ataków związanych z przechwytywaniem lub manipulowaniem danymi w trakcie transmisji, co może wpływać na bezpieczeństwo generowanych liczb losowych.

3.3.8 Podsumowanie wad TRNG

Chociaż TRNG oferują niezrównaną jakość losowości w porównaniu do rozwiązań opartych na algorytmach, posiadają również szereg wad, które mogą ograniczać ich szerokie zastosowanie. Należy do nich niska wydajność, wysokie koszty implementacji, problemy ze stabilnością generowanych liczb losowych, złożoność integracji z systemami oraz ryzyko związane z bezpieczeństwem. W miarę jak technologia będzie się rozwijać, możliwe jest, że te ograniczenia zostaną przezwyciężone, jednak obecnie stanowią one istotne wyzwanie dla szerokiego przyjęcia TRNG w różnych aplikacjach.

3.4 Podsumowanie dostępnych na rynku TRNG

Rozdział 4

Budowa sprzętowego generatora liczb losowych

sectionProjektowanie robota

Proces projektowania robota rozpoczęto od przeanalizowania różnych metod wykonywania rzutu kością. Ostatecznie, po przeanalizowaniu kilku koncepcji, zdecydowano się na rozwiązanie wykorzystujące obrotowy kubek, wewnątrz którego kość porusza się i odbija od ścianek. Taki mechanizm zapewnia losowość rzutu, a jednocześnie jest prosty w konstrukcji i intuicyjny w działaniu. Obracający się kubek został zaprojektowany tak, aby jego prędkość i czas trwania obrotu można było precyzyjnie kontrolować, co w założeniu pozwala na uzyskanie wiarygodnych wyników przy każdym rzucie. W celach testowych został skonstruowany prototypowy model robota, zbudowany w taki sposób, żeby wszystkie jego komponenty były modułowe. Takie rozwiązanie pozwala na łatwą wymianę elementów robota, bez potrzeby przeprojektowywania całego robota od nowa. Przy budowie wykorzystano technologię druku 3D, która pozwala na szybkie modyfikacje przy jednoczesnym zachowaniu bardzo wysokiej dokładności budowy elementów składowych.

Pierwszy prototyp robota składał się z metalowych prętów służących za stelaż oraz elementów wydrukowanych na drukarce 3D. Tymi elementami był: kubek, ramię służące do montażu kubka, uchwyty do prątów oraz płytka mocująca do kamery. Dodatkowo wykorzystano silnik prądu stałego napędzający kubek oraz sterownik służący do zasilania i sterowania ruchem silnika.

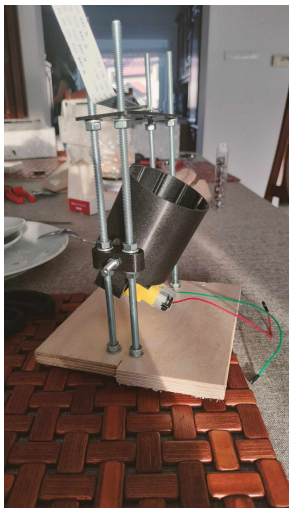

Rysunek 4.1: bałagan na stole

Po pierwszych testach okazało się, że niezbędny do uzyskania zamierzonego efektu będzie mechanizm, który będzie wychylał cały kubek wraz z silnikiem, który odpowiada za jego obrót. Z początku planowano wykorzystanie prostogo serwomechanizmu jednak to rozwiązanie odrzucono, ponieważ większość dostępnych serwomechanizmów, które byłyby odpowiednie w tym celu ma ograniczony ruch do 180° lub 360° a to limitowałoby możliwości mechanizmu służącego do wychylania kubka. Ostatecznie w tym celu wybrano mały silnik krokowy z wystarczającym momentem obrotowym (34.3mN.m). Silnik ten obraca układem dwóch kół zębatych 1:2 dzięki czemu silnik ma jeszcze większy zapas momentu obrotowego. Dzięki takiemu rozwiązaniu silnik nie pracuje na granicy swoich możliwości co zapewni jego długi okres eksploatacji.

Rysunek 4.2: zebatki

Podczas testów pierwszej wersji robota wykorzytującej obrotowy kubek powstał pomysł alternatywnego rozwiązania. Rozwiązanie to implementuje inne podejście do rzutu kością. Zamiast obracać cały kubek, a dodatkowo wyhylać go, wykorzystany został trwale zamontowany kubek, na którego dnie znajduje się śmigło, które podcina leżącą na dnie kość. Takie rozwiązanie znacząco upraszcza cały mechanizm robota oraz bardzo przyspiesza proces losowania liczby.

Przy projektowaniu drugiego wariantu robota został wykorzystany ten sam stelaż złożony z metalowych prętów co w pierwszym wariancie. Na drukarce 3D wydrukowano dodatkowe części, niezbędne do realizacji tego wariantu. Zaprojektowano i wydrukowano nowy kubek, śmigło oraz mocowanie dla silnika. Kubek został przystosowany do montażu silnika prądu stałego oraz śmigła.

W obu wariantach dużym problemem był słaby obraz z kamery. W tym celu zaprojektowano system oświetlenia składający się z diod LED, sterowanych za pomocą układu ULN2803A Darlington. Dzięki temu wnętrze kubka stało się dużo jaśniejsze, co pozwala kamerze na robienie zdjęć o wystarczająco dobrej jakości dla zamierzonego celu.

Duże znaczenie ma również wykorzystywana kość. Od jej koloru i tekstury zależy jakość zdjęć zrobionych przez zamonotowaną kamerę. Poniżej przedstawiono dwa przykłady zdjęć i różnic w ich czytelności zależnych od koloru kości.

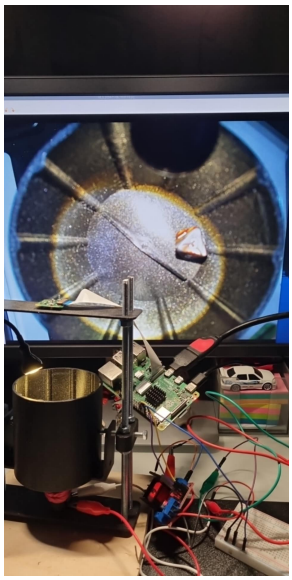

Rysunek 4.3: gorzej

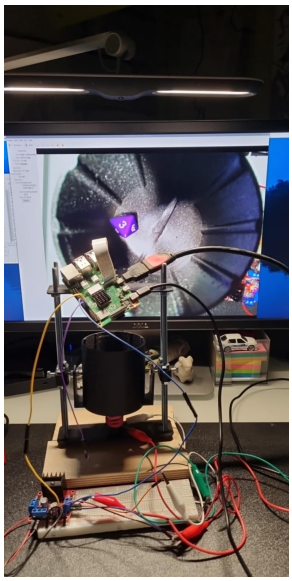

Rysunek 4.4: lepiej

W trakcie testów zauważono, że procesor robota nagrzewa się do wysokich temperatur podczas intensywnej pracy, co mogło negatywnie wpływać na jego wydajność i żywotność. Aby temu zapobiec, w projekcie zdecydowano się na zastosowanie dodatkowych rezystorów, które miały pomóc w rozproszeniu nadmiaru ciepła, oraz wentylatora, który wspomagał cyrkulację powietrza wokół procesora. Dzięki temu rozwiązaniu udało się obniżyć temperaturę pracy procesora, co zapewniło stabilne i bezpieczne działanie całego systemu.

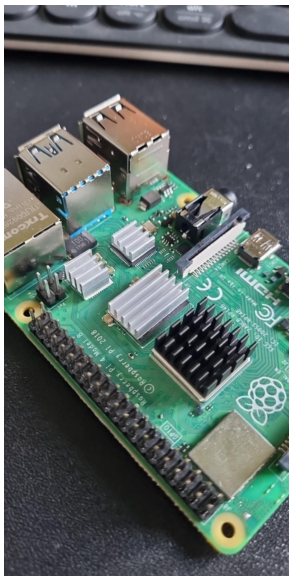

Rysunek 4.5: zimno

4.1 Dokumentacja techniczna

4.1.1 Hardware

aaaaaaaaaaaaaaa

4.1.2 Software

bbbbbbbbbbbbbbbbbbbb

Rozdział 5

Odczytywanie losowego wyniku z kości

5.1 Przetwarzanie wstępne obrazów

W niniejszym rozdziale omówiono proces przetwarzania wstępnego obrazów kości, który przekształca dane pochodzące z fizycznego komponentu naszej maszyny (zdjęcia kości) na dane wejściowe dla modelu sztucznej inteligencji. Przez dane wejściowe dla modelu SI rozumie się tutaj odpowiednio sformatowane obrazy, a więc takie w skali szarości, o rozmiarach 64x64 piksele, zawierające jedynie kość wyciętą ze zdjęcia całego bębna maszyny.

5.1.1 algorytm

Przedstawiony algorytm został zaimplementowany w języku Python, a jego zadaniem jest identyfikacja, wycięcie i przeskalowanie obszarów zawierających obiekty zainteresowania w zdjęciach.

Przetwarzanie obrazów składa się z kilku etapów, które dokładnie opisano poniżej, a workflow prezentuje się tak: Obraz wejściowy -¿ Odnalezienie kości za pomocą maski na komponencie nasycenia -¿ Stworzenie i wycięcie "Bounding Box"wokół maski -¿ Przeskalowanie do odpowiedniego rozmiaru -¿ Konwersja do skali szarości -¿ Zapisanie gotowego obrazu

Zdjęcia w formacie JPEG są wczytywane za pomocą biblioteki Pillow, a następnie konwertowane do przestrzeni kolorów RGB, co zapewnia jednolitość formatów danych wejściowych:

```
image = Image.open(image_path).convert("RGB")
```

Obrazy są przekształcane do przestrzeni barw HSV, aby oddzielić komponenty odpowiadające za barwę (H), nasycenie (S) oraz jasność (V). Nasycenie jest następnie wygładzane przy użyciu filtra Gaussa:

```
hsv_image = image.convert("HSV")
h, s, v = hsv_image.split()
blurred_v = s.filter(ImageFilter.GaussianBlur(radius=5))
```

Na podstawie komponentu nasycenia (S) oraz progowania tworzona jest maska binarna, która identyfikuje obszary o wysokim nasyceniu (a więc naszą kość):

```
v_array = np.array(blurred_v)
threshold = 224
binary_mask = (v_array > threshold).astype(np.uint8) * 255
```

W celu usunięcia niewielkich luk w masce binarnej stosowana jest operacja zamknięcia morfologicznego z wykorzystaniem strukturalnego elementu prostokątnego:

```
kernel = cv2.getStructuringElement(cv2.MORPH_RECT, (100, 100))
closed_mask = cv2.morphologyEx(binary_mask, cv2.MORPH_CLOSE, kernel)
```

Maska jest analizowana w celu zlokalizowania największego konturu, który określa obszar zainteresowania. Na tej podstawie oryginalny obraz jest kadrowany, a następnie przeskalowywany do wymiarów 64×64 pikseli:

```
contours, _ = cv2.findContours(closed_mask, cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE)
if contours:
    x, y, w, h = cv2.boundingRect(max(contours, key=cv2.contourArea))
    cropped_image = image.crop((x, y, x + w, y + h))
    resized_image = cropped_image.resize(size, Image.Resampling.LANCZOS)
```

Ostatecznie obraz jest konwertowany do skali szarości, co redukuje wymiarowość danych i umożliwia modelowi AI skupienie się na strukturze obrazu.

```
grayscale_image = resized_image.convert("L")
```

5.2 Podsumowanie

Przedstawiony algorytm przetwarzania wstępnego pozwala na skuteczne przygotowanie danych wejściowych dla modelu sztucznej inteligencji. Automatyzuje proces identyfikacji i kadrowania obiektów zainteresowania w obrazach, co znacząco poprawia jakość danych. Rozwiązanie zostało zaprojektowane z myślą o łatwej adaptacji do innych zastosowań wymagających podobnego przetwarzania obrazów.

5.3 Opis Modelu SI

Model sztucznej inteligencji został zaprojektowany w celu klasyfikacji zdjęć ośmiościennych kości do jednej z ośmiu klas, odpowiadających cyfrom od 1 do 8. Do implementacji modelu wykorzystano moduł Keras, który umożliwia łatwe tworzenie i trenowanie sieci neuronowych.

5.3.1 Przygotowanie danych

Dane wejściowe zostały podzielone na zestawy treningowy i walidacyjny w proporcji 70:30. W celu zwiększenia różnorodności danych treningowych zastosowano techniki augmentacji obrazów, takie jak:

- obrót o losowy kąt w zakresie do 90°,
- przesunięcia poziome i pionowe,
- transformacje perspektywiczne (shear) ,
- losowe powiększenia (zoom) .

Przykład konfiguracji generatora danych:

```
datagen = ImageDataGenerator(
    rescale=1.0 / 255.0,
    validation_split=0.3,
```

```
    rotation_range=90,
    width_shift_range=0.2,
    height_shift_range=0.2,
    shear_range=0.1,
    zoom_range=0.1
)
```

5.3.2 Architektura modelu

Model jest wielowarstwową siecią konwolucyjną (CNN) składającą się z następujących elementów:

- Warstwy wejściowej

```
layers.Input(shape=(64, 64, 1))
```

- Trzech warstw konwolucyjnych z funkcją aktywacji ReLU:

```
layers.Conv2D(32, (3, 3), activation='relu')
layers.MaxPooling2D((2, 2))
```

- Warstwy spłaszczającej (Flatten),
- Dwóch w pełni połączonych warstw (Dense), z których ostatnia używa funkcji aktywacji softmax do klasyfikacji na 8 klas:

```
layers.Dense(128, activation='relu')
layers.Dense(8, activation='softmax')
```

5.3.3 Trenowanie modelu

Model został skompilowany z wykorzystaniem optymalizatora Adam, funkcji strat sparse categorical crossentropy oraz metryki dokładności. Proces trenowania obejmował 20 epok:

```
model.compile(
    optimizer='adam',
    loss='sparse_categorical_crossentropy',
    metrics=['accuracy']
)
history = model.fit(
    train_data,
    validation_data=val_data,
    epochs=20,
    steps_per_epoch=train_data.samples,
    validation_steps=val_data.samples
)
```

5.3.4 Wyniki

Podczas trenowania osiągnięto następujące końcowe wyniki:

- Dokładność na zbiorze treningowym: `final_train_acc`,
- Dokładność na zbiorze walidacyjnym: `final_val_acc`,
- Strata na zbiorze treningowym: `final_train_loss`,
- Strata na zbiorze walidacyjnym: `final_val_loss`.

Wyniki zostały również zwizualizowane na wykresach przedstawiających zmianę dokładności i straty w trakcie trenowania. ¡Tu dać wykresy¿

Model został zapisany w formacie `keras` i jest gotowy do użycia w systemie rozpoznawania liczb na ośmiościennej kości, opisanym w kolejnej sekcji.

5.4 Funkcja predict

W celu rozpoznawania liczb na zdjęciach przetworzonych przez model stworzono funkcję `predict_number`, która przekształca obraz do odpowiedniego formatu i zwraca przewidywaną klasę. Funkcja działa w następujących krokach:

5.4.1 Wczytanie i przetworzenie obrazu

W przypadku funkcji dokonującej predykcji na pliku, obraz należy najpierw wczytać. Krok ten jest pomijany gdy do funkcji zostanie przekazany jako parametr obraz wczytany wcześniej. TODO (to jeszcze nie istnieje, ale będzie istnieć w finalnej części, gdzie przetwarzanie będzie bardziej "potokowe" niźli wstadowe jak teraz, jeśli tak to można określić) Obraz wejściowy wczytywany jest w trybie skali szarości i zmieniany na rozmiar zgodny z wymaganiami modelu (64×64 pikseli):

```
img = image.load_img(img_path, target_size=(64, 64), color_mode='grayscale')
img_array = image.img_to_array(img) / 255.0
img_array = np.expand_dims(img_array, axis=0)
```

Obraz jest normalizowany do zakresu $[0, 1]$, co pozwala na skuteczniejsze działanie sieci neuronowej.

5.4.2 Predykcja klasy

Przygotowany obraz jest przekazywany do modelu w celu uzyskania wyników predykcji:

```
prediction = model.predict(img_array)
predicted_class = np.argmax(prediction, axis=1)
```

Funkcja `np.argmax` zwraca indeks klasy o najwyższym prawdopodobieństwie.

5.4.3 Interpretacja wyniku

Na podstawie indeksu przewidywanej klasy wybierana jest odpowiadająca jej etykieta (od 1 do 8):

```
class_names = ['1', '2', '3', '4', '5', '6', '7', '8']
predicted_label = class_names[predicted_class[0]]
return predicted_label
```

Wynik funkcji to etykieta odpowiadająca numerowi na kości, co umożliwia dalsze wykorzystanie tego wyniku w systemie rozpoznawania liczb.

5.5 Przetwarzanie wyniku

Finalnie, zaetykietowany wynik przetwarzany jest na ciąg trzech bitów, odpowiadających etykiecie klasy. Wyjątkiem w tym przetwarzaniu jest etykieta 8, gdyż w zapisie binarnym zawierała by 4 bity, zamiast oczekiwanych trzech, jednak biorąc 3 najmniej znaczące bity (000) jesteśmy w stanie zapewnić unikatowe kodowanie każdemu wynikowi. W ten sposób, klasy 1-7 generują bity będące ich dosłowną reprezentacją binarną, a 8 jest równoznaczne wyrzuceniu "zera"na kostce.

Rozdział 6

Testy

Przez wzgląd na brak oprogramowania, nie da się przeprowadzić typowej oceny jakości projektu. Zamiast tego, postanowiono sprawadzić losowość odczytanych wyników rzutu kością dla obu wariantów robota, a następnie porównać je między sobą oraz z losowością wbudowanego generatora pseudolosowego programu Python.

Do oceny losowości otrzymanych wyników użyto:

- test chi-kwadrat,
- test pojedynczych bitów,
- test serii,
- test długiej serii,
- test pokerowy
- procentową wartość entropii.

Dla otrzymania wystarczającej ilości danych, należało wygenerować 20 000 bitów. Ponieważ robot używa kości ośmiościennej, dającej wynik w postaci dokładnie 3 bitów, należało wykonać 6 667 rzutów.

6.1 Użyte wzory

6.1.1 Test chi-kwadrat

Aby przeprowadzić ten test, dla wszystkich n rzutów zliczono, ile razy wypadła każda z k ścian kości ośmiościennej (O_i). Wyniki te porównano z oczekiwaną liczbą wyrzucenia każdej ze ścianek $E_i = \frac{n}{k}$.

$$\chi^2 = \sum_{i=1}^{k} \left(\frac{O_i - E_i}{E_i} \right)^2$$

Ponieważ do generowania liczb losowych użyto kości ośmiościennej, to k jest równe 8, co daje wzór:

$$\chi^2 = \sum_{i=1}^{8} \left(\frac{O_i - E_i}{E_i} \right)^2$$

Dla przeprowadzonych testów wybrano poziom istotności $p = 0,5$, natomiast stopień swobody przy $k = 8$ równa się:

$$k - 1 = 8 - 1 = 7$$

Zatem dla otrzymanego stopnia swobody oraz założonego stopnia istotności, wartość krytyczna wynosi $14,0671$. Test jest zakończony sukcesem, jeśli otrzymana wartość będzie mniejsza od wartości krtycznej.

6.1.2 Entropia

$$H(X) = -\sum_{i=1}^{k} p(x_i)\, log_2 p(x_i)$$

Ponieważ wartość entropii jest wyznaczana dla bitów, a każdy rzut na kości ośmiościennej daje wynik w 3 bitach, wartość entropii przeprowadzonego testu może wynosić maksymalnie 3.

6.1.3 Test pojedynczych bitów

Dla wszystkich wygenerowanych bitów zliczono, ile razy wystąpiły 0 (n_0) i ile razy wystąpiły 1 (n_1). Test jest zakończony sukcesem, jeśli każda z tych wartości spełnia zależność:

$$9725 < n_0 < 10275$$

$$9725 < n_1 < 10275$$

6.1.4 Test serii

Jednocześnie dla ciągu wygenerowanych bitów zliczono tzw. serie, czyli ile razy bez przerw występuje podciąg zer lub jedynek o długościach od jednego do pięciu takiego samego bitu pod rząd. Dłuższe serie zliczono do jednej kategorii. Aby test został zakończony sukcesem, liczba serii danych długości dla zarówno zer jak i jedynek musi spełniać zależność przedstawioną w poniższej tabeli.

Długość serii	Przedział
1	2315 - 2685
2	1114 - 1386
3	527 - 723
4	240 - 384
5	103 - 209
6 i więcej	103 - 209

6.1.5 Test najdłuższej serii

Przy zliczaniu bitów dla testu serii, jednocześnie szukano najdłuższego podciągu samych zer i najdłuższego podciągu samych jedynek. Test długiej serii jest zakończony sukcesem, jeśli żaden z tych podciągów nie zawiera więcej niż 25 bitów.

6.1.6 Test pokerowy

Do przeprowadzenia testu pokerowego podzielono wygenerowany ciąg na czwórki bitów, a następnie zliczono, ile razy wystąpiła każda z szesnastu kombinacji s_i. Test jest zakończony sukcesem, jeśli spełniona jest poniższa nierówność:

$$2,16 < X < 46,17$$

Gdzie:

$$X = \frac{16}{5000} \sum_{i=0}^{15} s_i^2 - 5000$$

6.2 Testy poszczególnych wariantów

Coś tam coś tam, mamy dwa warianty robota to możemy je porównać. (jeśli będzie czas na testowanie betoniarki)

6.2.1 Wariant 1 - „Betoniarka“

6.2.2 Wariant 2 - „Blender“

Rozdział 7

Zakończenie

Zakończenie pracy Lorem Ipsum Dolor sit itd. itp.

Instytut Informatyki, Wydział Informatyki i Telekomunikacji
Politechnika Poznańska

Skład przy użyciu systemu LaTeX - MiKTeX oraz workflow za pomocą Github Actions.